

# Charakteristiky variability

## Charakteristiky variability (proměnlivosti souboru)

[Statistické znaky](#) jako číselné proměnné jsou vždy různě variabilní (proměnlivé). Malý stupeň variability znamená malou vzájemnou různost (velkou podobnost) hodnot dané proměnné, což zároveň signalizuje, že [střední hodnota](#) (průměr), [medián](#) a případně i [modus](#) jsou v tomto případě dobrými charakteristikami obecné velikosti hodnot dané proměnné v daném [souboru](#). Naopak vysoká variabilita značí velkou vzájemnou odlišnost hodnot dané proměnné, což zároveň signalizuje, že vypočítané parametry středu souboru nejsou v tomto případě dobrými charakteristikami obecné výše hodnot dané proměnné v daném souboru.

Charakteristiky středu souboru ([střední hodnoty](#)) udávají pouze informaci o poloze statistického souboru na číselné ose, ale neudávají, jak jsou hodnoty v souboru rozptýleny kolem středu, případně, zda existují v souboru tzv. [extrémní hodnoty](#). Tuto informaci poskytují tzv. **míry variability** (charakteristiky variability), které vyjadřují rozmístění hodnot dané proměnné okolo střední hodnoty celého souboru.

### 1. Variační rozpětí (The Range)

(označení:  $R$ )

Variační rozpětí  $R$  řady  $n$  čísel můžeme definovat jako rozdíl mezi největší a nejmenší hodnotou řady (rozdíl mezi největší a nejmenší hodnotou znaku v souboru):

$$R = x_{\max} - x_{\min}$$

Variační rozpětí není příliš přesnou charakteristikou variability hodnot sledované numerické proměnné, neboť je ovlivněno velikostí extrémních hodnot a zároveň neříká nic o tom, jak se chovají hodnoty uvnitř souboru.

Tento nedostatek  $R$  překonávají rozpětí [kvantilů](#), z nichž nejpoužívanější je *kvartilové rozpětí*  $R_q$ :

$$R_q = x_{0,75} - x_{0,25}$$

Je zřejmé, že variační rozpětí ani kvartilová rozpětí neberou při charakterizování variability v úvahu velikost všech hodnot sledované numerické proměnné, což je mnohdy považováno jako závažný nedostatek.

### 2. Rozptyl (variance, The variance)

$s^2$  (základní soubor),  $s^2$  (výběrový soubor)

Rozptyl můžeme definovat (jako přesný parametr populace) jako [aritmický průměr](#) čtverců odchylek jednotlivých hodnot sledované proměnné  $x_i$  od průměru celého souboru:

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N} \quad (\text{rozptyl } \text{základního souboru})$$

Pohlíží-li se na daný soubor jako na výběrový, potom mluvíme o *výběrovém rozptylu*  $s^2$ , který slouží jako odhad skutečného rozptylu populace a jeho výpočet se poněkud liší. U výpočtu výběrového rozptylu je ve jmenovateli výraz  $(n-1)$ , který označujeme jako *počet stupňů volnosti* výběrového souboru (blíže viz Předn.2: [Odhady parametrů základního souboru](#)). Použitím tohoto výrazu  $(n-1)$  místo prosté velikosti souboru  $n$  docílíme přesnějšího odhadu skutečné hodnoty populačního rozptylu, především při výpočtu na základě malých výběrových souborů:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \quad (\text{rozptyl } \text{výběrového souboru})$$

Z obou výpočtů je zřejmé, že rozdíl mezi rozptylem  $s^2$  na jedné straně a výběrovým rozptylem  $s^2$  na druhé straně je při velkém [rozsahu souboru](#) ( $n > 30$ ) prakticky zanedbatelný.

Při praktických výpočtech podle výše uvedeného vzorce výběrového rozptylu by byl postup příliš zdlouhavý (především u velkých výběrových souborů), proto je možno pro usnadnění použít ještě jinou variantu vzorce pro výpočet výběrového rozptylu:

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{\left(\sum_{i=1}^n x_i\right)^2}{n}}{n-1}$$

### Vlastnosti rozptylu:

- jestliže jsou všechny hodnoty souboru stejné, potom je variabilita hodnot sledované proměnné v souboru nulová a výběrový rozptyl  $s^2 = 0$
- velikost rozptylu se zvyšuje při zvětšující se variabilitě hodnot sledované proměnné
- rozptyl je odvozen od součtu čtverců odchylek jednotlivých hodnot od průměru souboru, proto nemůže nikdy nebývat záporných hodnot
- přičte-li se ke všem hodnotám (odečte-li se od všech hodnot) proměnné  $X$  libovolná kladná konstanta  $a$ , potom se rozptyl nezmění:

$$\sigma^2(X \pm a) = \frac{1}{n} \sum_{i=1}^n (x_i \pm a - \bar{x} \pm a)^2 = \sigma^2$$

- násobí-li se (dělí-li se) všechny hodnoty proměnné nenulovou konstantou  $g$ , potom je rozptyl znásoben (vydělen) čtvercem této konstanty:

$$\sigma^2(g \cdot X) = \frac{1}{n} \sum_{i=1}^n (g \cdot x_i - g \cdot \bar{x})^2 = g^2 \cdot \sigma^2$$

- rozptyl je uveden ve čtvercích měrných jednotek hodnot sledovaných číselných proměnných (vyplývá to z definice rozptylu). Např.: jestliže budou hodnoty sledované proměnné vyjádřeny v gramech, jejich rozptyl bude v g<sup>2</sup>. Jestliže hodnoty sledované proměnné budou vyjádřeny v cm<sup>2</sup>, rozptyl těchto hodnot bude vyjádřen v (cm<sup>2</sup>)<sup>2</sup>, bez ohledu na to, že takové jednotky nemají žádný fyzikální význam.

### 3. Směrodatná odchylka (standardní deviace, Standard Deviation - SD)

$\sigma$  (základní soubor),  $s$  (výběrový soubor)

Směrodatná odchylka je definována jako (kladná) druhá odmocnina z rozptylu, tj.

$$\sigma = \sqrt{\sigma^2} \text{ pro základní soubor,}$$

případně

$$s = \sqrt{s^2} \text{ pro výběrový soubor.}$$

Výpočet **směrodatné odchylky pro [základní soubor](#)**:

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}} \quad \sigma = \sqrt{\frac{\sum x_i^2 - \frac{(\sum x_i)^2}{N}}{N}} \quad \text{nebo}$$

Výpočet **směrodatné odchylky pro [výběrový soubor](#)**:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} \quad \text{nebo} \quad s = \sqrt{\frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n-1}}$$

#### Vlastnosti směrodatné odchylky:

- směrodatná odchylka má stejné měrné jednotky jako sledovaná číselná proměnná ve statistickém souboru
- směrodatná odchylka může nabývat vždy pouze kladných hodnot (vyplývá z definice)

### 4. Variační koeficient (The Coefficient of Variation)

(„relativní směrodatná odchylka“)

Variační koeficient je vhodný pro vzájemné srovnávání variability dvou nebo více souborů s podstatně odlišnou úrovní hodnot (např. variabilitu váhy kuřat v gramech a variabilitu váhy skotu v kg nebo metrických centech). V těchto případech musíme odstranit vliv obecné úrovně daných hodnot. Děláme to tak, že [směrodatnou odchylku](#) dělíme střední hodnotou, od které byly počítány odchylky pro součet čtverců, obvykle tedy při praktických výpočtech aritmetickým průměrem výběrového souboru. Výsledek se obvykle vyjadřuje v procentech (po vynásobení 100).

Variační koeficient je tedy definován pro **základní soubor**:

$$V = \frac{\sigma * 100}{\mu} \quad [\%]$$

Pro **výběrový soubor** vypočteme prakticky variační koeficient podle vzorce:

$$V = \frac{s * 100}{\bar{x}} \quad [\%]$$

### Vlastnosti variačního koeficientu:

- variační koeficient je relativní mírou variability a není ovlivněn absolutními hodnotami sledovaného statistického znaku
- variační koeficient udává, z kolika procent se podílí směrodatná odchylka na [aritmetickém průměru](#)
- přičte-li se ke všem hodnotám (odečte-li se od všech hodnot) dané proměnné libovolná kladná konstanta  $a$ , potom se variační koeficient zmenší (zvětší:

$$V(X + a) = \frac{\sigma}{\bar{x} + a} < \frac{\sigma}{\bar{x}} = V$$

resp.:

$$V(X - a) = \frac{\sigma}{\bar{x} - a} > \frac{\sigma}{\bar{x}} = V$$

- násobí-li (dělí-li) se všechny hodnoty proměnné  $X$  nenulovou konstantou  $g$ , potom se variační koeficient nezmění:

$$V(gX) = \frac{g\sigma}{g\bar{x}} = \frac{\sigma}{\bar{x}} = V$$

## 5. Střední chyba průměru (Standard Error of Mean - SE, SEM)

$\sigma_x$  (základní soubor),  $s_x$  (výběrový soubor)

**Střední (směrodatná) chyba průměru** patří mezi často používané relativní míry variability. Často je označována (především v zahraniční odborné literatuře) zkratkou SE (příp. SEM) – z anglického výrazu Standard Error of Mean. Střední chyba průměru neměří rozptýlenost původní náhodné proměnné, ale rozptýlenost vypočítaného [aritmetického průměru](#) v různých výběrových souborech vybraných z jednoho [základního souboru](#).

Střední (směrodatná) chyba průměru je teoreticky definována jako [směrodatná odchylka](#) všech možných výběrových průměrů z jedné populace, vypočítaných pro výběry o rozsahu  $n$  členů. Vyjadřuje tedy kolísání výběrových průměrů kolem teoretické (skutečné) [střední hodnoty](#)  $m$  v celém základním souboru.

Střední chyba průměru závisí jednak na rozptylu základního souboru ( $s^2$ ), jednak na rozsahu výběrového souboru ( $n$ ):

$$\sigma_x = \frac{\sigma}{\sqrt{n}}$$

Protože v praxi obvykle neznáme skutečnou hodnotu rozptylu s celého základního souboru, používáme prakticky výpočet pro **výběrovou střední chybu průměru** podle vzorce:

$$s_x = \frac{s}{\sqrt{n}}$$

Výběrová střední chyba průměru ( $s_x$ ) může být použita jako míra přesnosti, s jakou výběrový aritmetický průměr  $\bar{x}$  odhaduje skutečnou střední hodnotu  $m$ . Prakticky se používá pro výpočet intervalů spolehlivosti aritmetického průměru u výběrových souborů (blíže viz [Odhady parametrů základního souboru](#)).

[Zpět](#)